



INSTITUTO FEDERAL DO NORTE DE MINAS GERAIS
CAMPUS MONTES CLAROS -MG
CIÊNCIA DA COMPUTAÇÃO



SARAH EMANUELLE ALVES LINO
TAINARA RIBEIRO SANTOS

RELATÓRIO: PRÁTICA DE LABORATÓRIO 5

Relatório apresentado ao Professor Wagner Ferreira de Barros como parte das exigências de avaliação da disciplina de Organização e Sistemas de Arquivos do Curso de Bacharelado em Ciência da Computação do Instituto Federal do Norte de Minas Gerais, Campus Montes Claros.

MONTES CLAROS - MG

2025

Relatório do Projeto: Sistema de Indexação e Busca com Índices Invertidos

O objetivo principal desta prática foi projetar e implementar um sistema de indexação e busca utilizando índices invertidos, capaz de lidar com arquivos de dados extensos. Este sistema deve suportar buscas por títulos ou partes dos títulos de registros, aplicando técnicas de exclusão de palavras irrelevantes (Stopwords) para aprimorar a precisão dos resultados. Deste modo, explorando a implementação de estruturas de dados avançadas, como índices primários e invertidos, para a resolução de problemas de recuperação de informações em grande escala.

Logo, a prática visa proporcionar uma experiência prática no desenvolvimento de sistemas de software que envolve o gerenciamento que seja eficiente de dados de arquivos, abordando conceitos da disciplina de Organização e Sistemas de Arquivos e reforçando a aplicação por meio da prática desses conhecimentos.

1. Estrutura do Projeto

1.1 Criação dos Arquivos

Para a realização do trabalho, foi necessário a criação das classes, onde cada classe era responsável por algumas funcionalidades específicas, destacadas a seguir:

- *Buffer.h* e *Buffer.cpp* : Contém a lógica principal do programa para lidar com operações no arquivo binário e mantém a consistência dos índices, assim permitindo a gravação no formato binário e a leitura de registros utilizando descritores de tamanho.
- *Index.h* e *Index.cpp* : Implementa um índice que associa o ID do registro do livro à sua posição no arquivo binário; suportando gravações de novos registros.
- *Registro.h* e *Registro.cpp* : Define a estrutura de um registro de livro, com atribuição como o ID do livro, título, autores, ano de publicação e gênero, como também a utilizado métodos de compactação, como o *packDescriptor*, e descompactação, como *unpackDescriptor*; assim permitido o armazenamento e a recuperação de registros do arquivo binário.
- *BooksDataset.csv* : Contém todos os registros originais oferecidos.

- *IndexInvert.bin* : Classe responsável por associar as palavras-chaves dos títulos fornecidos pelo *BooksDataset.csv* , aos registros correspondentes.
- *Stopwords.txt* : Contém palavras comuns que serão excluídas durante a indexação.
- *Pontuacao.txt* : Inclui todos os símbolos que serão ignorados durante a indexação.

1.2 Estruturas Auxiliares

- *Arvore.h* : Implementa uma Árvore Binária de Pesquisa (ABP) para organizar os índices em memória. Esta implementação suporta operações de inserção, busca e remoção.
- *Fila.h* e *Pilha.h* : Implementar dinâmicas para suportar percursos em largura e profundidade na árvore de índices.

1.3 Código Principal

- *main.cpp* : Realiza a leitura dos dados do arquivo CSV, processa os registros e os armazena no arquivo binário, realizando consultas, adiciona novos registros e valida a consistência dos índices.

2. Metodologia

A metodologia adotada para este trabalho visa garantir uma indexação eficiente e uma busca rápida em um arquivo binário de grande porte, utilizando índices primários e invertidos. O processo ocorre em diversas etapas, iniciando-se com a leitura do arquivo CSV contendo os registros, onde os campos são delimitados por "|". Cada registro é convertido para um formato binário estruturado, com um descritor de tamanho de 4 bytes armazenando o tamanho total do registro, seguido pelos dados do registro. Após isso, novos registros são adicionados ao final do arquivo binário, garantindo uma organização eficiente e minimizando a fragmentação. Para facilitar a recuperação de dados, foram utilizados dois tipos de índices.

O índice primário tem a função de associar cada registro a um identificador único (ID) e sua respectiva posição no arquivo binário. Esses índices são armazenados em uma Árvore Binária de Pesquisa (ABP), que permite uma busca eficiente. Os índices primários são periodicamente salvos no arquivo "IndexInvert.bin" para garantir persistência. Além disso, um índice invertido é criado para busca eficiente por título ou palavras contidas nos títulos.

Esse índice mapeia cada palavra significativa de um título para uma lista de IDs dos registros que a contém, sendo armazenado em um arquivo binário separado para acesso rápido e otimizado.

Para garantir que apenas palavras relevantes sejam indexadas, é realizado um filtro que remove palavras irrelevantes (stopwords) utilizando um conjunto não ordenado (`unordered_set`) para acesso eficiente. Sinais de pontuação também são removidos para padronizar a indexação e a busca. A recuperação de registros ocorre em duas etapas. Primeiro, a palavra-chave fornecida é buscada no índice invertido, retornando uma lista de IDs correspondentes.

Depois, com base nos IDs obtidos, a Árvore Binária de Pesquisa é utilizada para encontrar a posição do registro no arquivo binário, permitindo o acesso direto ao dado. Para otimizar o processamento, são utilizadas estruturas auxiliares como fila para percorrer a árvore em largura (BFS) e pilha para percorrer em profundidade (DFS). A entrada de dados é feita via prompt de comando, permitindo buscas por palavras-chave ou frases, enquanto os resultados são exibidos de forma organizada, possibilitando a navegação entre os registros encontrados, seja avançando, retrocedendo ou visualizando um item específico.

3. Teste Realizados e Resultados

Os testes realizados tiveram como objetivo avaliar a precisão e eficiência do mecanismo de busca. Para isso, foram utilizadas palavras-chave e frases como "Books", "American" e "New York" e "Dog", permitindo verificar se o sistema retorna corretamente todos os títulos que contêm esses termos. A seguir está o retorno dos dois últimos registros mostrados no terminal e a quantidade encontrada dessa recorrência ao realizar a busca pela palavras mencionadas:

- Books:

```
ID = 3102 | Endereço = 11451959
```

```
ID: 3102
```

```
Título: Zachary's Ball (Tavares baseball books)
```

```
Autor: Tavares, Matt
```

```
Ano de Publicação: 2000
```

```
Gênero: Juvenile Fiction , Family , Parents
```

```
ID = 40972 | Endereço = 11461034
```

```
ID: 40972
```

Título: Zip! Pop! Hop! and Other Fun Words to Say (First Little Golden Books)
Autor: Muntean, Michaela and Prebenna, David (ILT)
Ano de Publicação: 1999
Gênero: Juvenile Fiction , Media Tie-In

Quantidade de livros achados: 1442

- American:

ID = 32709 | Endereço = 11450358

ID: 32709
Título: Yucatan Before and After the Conquest (Native American)
Autor: Landa, Diego de
Ano de Publicação: 2012
Gênero: History , Latin America , Mexico

ID = 70618 | Endereço = 11464914

ID: 70618
Título: Zuni Fetishes: Using Native American Sacred Objects for Meditation, Reflection, and Insight
Autor: Bennett, Hal Zina
Ano de Publicação: 1993
Gênero: Social Science , Folklore & Mythology

Quantidade de livros achados: 2777

- New York:

ID = 102888 | Endereço = 5945946

ID: 102888
Título: New York Jew
Autor: Kazin, Alfred
Ano de Publicação: 1979
Gênero:

ID = 102931 | Endereço = 9485960

ID: 102931
Título: The New York Times Book of Trees and Shrubs
Autor: Joan Lee Faust, Editor
Ano de Publicação: 1967
Gênero:

Quantidade de livros achados: 236

- Dog:

ID = 37243 | Endereço = 11402424

ID: 37243

Título: You Know Your Dog Owns You If

Autor: Chapman, Chaz and Curtis, Stacy

Ano de Publicação: 2004

Gênero: Humor , Topic , Animals

ID = 9599 | Endereço = 11433371

ID: 9599

Título: Your Outta Control Adopted Dog

Autor: Adamson, Eve

Ano de Publicação: 2003

Gênero: Pets , Reference

Quantidade de livros achados: 474

Durante os testes, foi analisado o tempo de resposta para diferentes tamanhos de arquivos, garantindo que a busca permaneça eficiente mesmo em grandes volumes de dados. Foram também testados cenários de busca parcial e completa, considerando diferentes combinações de palavras e verificação da correta exclusão de stopwords e também das pontuações fornecidas no arquivo.

Como resultado, o sistema demonstrou um desempenho satisfatório, retornando os registros relevantes de forma rápida e precisa, garantindo a robustez do método implementado.

4. Conclusão

Logo, é possível dizer que todos os objetivos propostos no desenvolvimento do projeto foram atendidos, já que resultou em um sistema eficaz e expansível para a busca dos registros. As técnicas empregadas podem ser convenientemente aplicadas para resolver problemas reais enfrentados ao administrar arquivos de dados.

Nesse sentido, pode-se dizer que a utilização de índices primário e invertido se mostrou uma técnica extremamente eficaz na reestruturação de grandes quantidades de dados.

Durante o desenvolvimento do sistema, desafios como a organização deste índice, e remoção eficaz de stopwords e das pontuações para melhorar a qualidade do algoritmo foram superados, ajudando a potencializar e melhorar a precisão do sistema implementado.